


# Chapitre 1


## Désaisonnalisation et Décomposition des Séries Temporelles


Techniques de Prévision et Conjoncture (M1 EKAP)  
2020-2021

Olivier DARNÉ



- Hyndman et Athanasopoulos (2018), *Forecasting: Principles and Practice*, OTexts. [online]
- Eurostat (2018), *Handbook of Seasonal Adjustment*, European Commission.
- Aragon (2016), *Série temporelles avec R*, Springer.





## Les composantes inobservables

W.M. Persons (1919) a donné une définition et une formalisation standards des **composantes inobservables** (*unobserved components*, UC) d'une série temporelle  $X_t$  observée, largement popularisées par les succès du baromètre de Harvard (analyse et prédiction du cycle) fondé sur cette méthodologie.

Il distingue quatre types d'éléments :

- une **tendance de long terme** ou **tendance séculaire** :  $T_t$
- un **mouvement cyclique** superposé sur la tendance :  $C_t$
- un **mouvement saisonnier**, cad un mouvement cyclique relativement régulier de période intra-annuelle :  $S_t$
- une **variation résiduelle** :  $I_t$

Cette composante rassemble tout ce que les autres composantes n'ont pu expliquer du phénomène observé (fluctuations accidentelles, catastrophes naturelles, guerres ...)

Ces composantes inobservables peuvent être combinées selon les schémas de décomposition additif ou multiplicatif (idée ancienne datant des travaux de Buys Ballot, 1847)

$$\text{Schéma additif :} \quad X_t = TC_t + S_t + I_t$$

$$\text{Schéma multiplicatif :} \quad X_t = TC_t \times S_t \times I_t$$

$$\Leftrightarrow \text{Schéma log-multiplicatif :} \quad \log(X_t) = \log(TC_t) + \log(S_t) + \log(I_t)$$

avec  $TC_t$  : la **composante de tendance-cycle** ou **tendance de court terme**.

La **composante cyclique** est un phénomène se répétant mais contrairement à la saisonnalité sur des durées qui ne sont pas fixes et généralement plus longues. Sans informations spécifiques, il est généralement très difficile de dissocier tendance et cycle, notamment les séries courtes (15 à 20 années de données)

Par conséquent, on regroupe ces deux composantes pour former celle de tendance-cycle, aussi appelé **extra-saisonnier**

De nos jours, les schémas de décomposition des différents éléments tiennent compte des **composantes déterministes** qui affectent un certain nombre de chroniques socio-économiques (notamment celles de flux), telles que les variations de jours ouvrables (CJO) ou les effets de fêtes mobiles

Ces schémas s'écrivent alors :

Schéma additif : 
$$X_t = TC_t + S_t + WD_t + EE_t + I_t$$

Schéma multiplicatif : 
$$X_t = TC_t \times S_t \times TD_t \times HE_t \times I_t$$

$\Leftrightarrow$  Schéma log-multiplicatif : 
$$\log(X_t) = \log(TC_t) + \log(S_t) + \log(WD_t) + \log(EE_t) + \log(I_t)$$

- $WD_t$  : **composante de jours ouvrables** (*Working Days*) mesurant l'impact sur la série de la composition journalière du mois
- $HE_t$  : **composante mesurant l'effet jours de vacances** (*Holiday Effect*).

On parle plus généralement des effets de fêtes mobiles (*moving holiday effects*) pour caractériser les effets provoqués par les fêtes qui tombent dans un mois ou dans un autre, selon le calendrier. (fête du travail, fête de Pâques, Thanksgiving ...)

## Détection de la saisonnalité

Un certain nombre de **tests de saisonnalité** sont disponibles afin de savoir s'il est nécessaire ou pas de désaisonnaliser la série : **étape préliminaire indispensable**

Chaque test est basée sur l'hypothèse nulle  $H_0$  d'absence de saisonnalité, en supposant que

- la série est  $\{z_t\}$  est stationnaire (ou rendue stationnaire)
- $T$  le nombre d'observations
- $s$  observations par année

Les 5 tests sont les suivants :

- le test QS modifié
- le test de Friedman
- le test de Kruskal-Wallis
- le test du périodogramme
- le  $F$ -test sur des variables dichotomiques saisonnières (*seasonal dummies*)



**Le test QS modifié (QS)** : il contrôle si la série présente des autocorrélation positives significatives aux retards saisonniers :

$$QS = T(T+2) \left( \frac{\hat{\rho}^2(s)}{T-s} + \frac{[\max\{0, \hat{\rho}(2s)\}]^2}{T-2s} \right) \sim \chi^2(2)$$

avec  $\rho(h) = \gamma(h)/\gamma(0)$  l'autocorrélation d'ordre  $h$ , où  $\gamma(h) = E[z_{t+h}z_t] - [E(z_t)]^2$  est l'autocovariance à l'ordre  $h$ . Si  $\hat{\rho}(s) < 0$  alors  $QS = 0$ .

**Le test de Friedman (FT)** : il contrôle les différences significatives entre les rangs moyens à des périodes spécifiques pour les observations :

$$FT = \frac{s-1}{s} \sum_{i=1}^s \frac{n[\bar{r}_i - (s+1)/2]^2}{(s^2-1)/12} \sim \chi^2(s-1)$$

en supposant que chaque période  $i = 1, \dots, s$  possède  $n$  observations, et avec  $\bar{r}_i$  le rang moyen des observation dans la période  $i$ , où les rangs sont assignés séparément pour chaque année.

**Le test de Kruskal-Wallis (KW)** : il suit la même idée que le test de Friedman mais se base sur le nombre d'observations spécifique à chaque période  $n_i$  et assigne les rangs sur la période d'observation entière :

$$KW = \frac{T-1}{T} \sum_{i=1}^s \frac{n_i [\bar{r}_i - (T+1)/2]^2}{(T^2-1)/12} \sim \chi^2(s-1)$$

Les tests FT et KW peuvent être interprétés comme des tests ANOVA

**Le test du périodogramme (PD)** : il contrôle si la somme pondérée de l'estimateur du périodogramme aux fréquences saisonnières est significativement différentes de zéro. L'estimateur est donné par  $(2\pi)^{-1} I(\omega_j)$  avec

$$I(\omega_j) = \begin{cases} \frac{\sum_{|h| \leq T} \hat{\gamma}(h) e^{-ih\omega_j}}{T|\bar{z}|^2} & \text{si } \omega_j \neq 0 \\ 0 & \text{si } \omega_j = 0 \end{cases}$$

où  $\omega_j = 2\pi j/T$  est la  $j$ -ième fréquence de Fourier pour  $j = -\lfloor (T-1)/2 \rfloor, \dots, \lfloor (T-1)/2 \rfloor$ , avec  $\lfloor x \rfloor$  le plus grand entier n'excédant pas  $x$ .

La somme pondérée de l'estimateur du périodogramme aux fréquences saisonnières suit une distribution de Fisher  $F(s-1; T-s)$

**Le F-test sur des variables dichotomiques saisonnières (SD)** : il contrôle si les effets des  $(s - 1)$  variables dichotomiques dans le modèle RegARIMA sont tous nuls de manière simultanée.

Le modèle RegARIMA inclue un modèle SARIMA non saisonnier (ou ARIMA) + variable dichotomiques saisonnières :

$$ARIMA(p, d, q) + \mu + \sum_{i=1}^{s-1} \beta_i D_{i,t}$$

Une version pose le modèle  $ARIMA(p, d, q) = ARIMA(0, 1, 1)$ , et une seconde détermine les ordres  $p, d, q$  via l'algorithme de Hannan-Rissanen. Le test est

$$SD = \frac{\hat{\beta}' Cov(\hat{\beta})^{-1} \hat{\beta}}{s-1} \times \frac{T-d-p-q-s-1}{T-d-p-q} \sim F(s-1; T-d-p-q-s-1)$$

avec  $\hat{\beta}$  le vecteur des coefficients estimés des variables dichotomiques saisonnières.

Le R package [seastest](#) de Ollech (2019) [\[pdf\]](#) permet d'utiliser ces 5 tests également disponibles dans JDemetra et RegARIMA.

Basé sur les travaux de Webel et Ollech (2019) le package propose un nouveau test combinant les tests QS et KW avec la fonction `wo`

Pour le test SD, la sélection automatique des ordres du modèle ARIMA est réalisée à partir de l'algorithme de Hyndman et Khandakar (2008) [\[pdf\]](#), également utilisé dans la fonction `auto.arima` du package [forecast](#) :

- sélection de l'ordre de différenciation  $d$  par le test de racine unitaire KPSS
- sélection des polynômes non saisonniers  $p$  et  $q$  en minimisant le critère AICc, avec  $\max(p) = \max(q) \leq 3$
- la recherche se fait pas à pas (*stepwise*)

```
library(readxl)
library(seastests)
y <- read.table("c://R//data//demandbrut.txt")
yy <- ts(data = y, start=c(1996,01),frequency=12)

# Friedman test
ft <- fried(yy)
show(ft)
# Testing the seasonality of series
# a boolean value is returned : TRUE or FALSE
is <- isSeasonal(yy, test="wo")
show(is)
# Kruskal-Wallis test
kwt <- kw(yy)
show(kwt)
# QS test
qst <- qs(yy)
show(qst)
# Seasonal dummies (SD)
sd <- seasdum(yy)
show(sd)
# Welch test
w <- welch(yy)
show(w)
# Weibel-Öllech test
wot <- wo(yy)
show(wot)
```

## # Friedman test

Test used: Friedman rank

Test statistic: 205.41

P-value: 0

## # Testing the seasonality of series

[1] TRUE

## # Kruskal-Wallis test

Test used: Kruskal Wallis

Test statistic: 223.92

P-value: 0

## # QS test

Test used: QS

Test statistic: 398.29

P-value: 0

## # Seasonal dummies (SD)

Test used: SeasonalDummies

Test statistic: 139.15

P-value: 0

## # Welch test

Test used: Kruskal Wallis

Test statistic: 139.8

P-value: 5.772899e-55

## # Webel-Ollech test

Test used: WO


Test statistic: 1

P-value: 0 0 0


## Choix du modèle (additif ou multiplicatif)

Avant toute modélisation et étude approfondie du modèle, on tente d'abord de déterminer si on est en présence d'une spécification additive ou multiplicative

**Additive Model**




**Multiplicative Model**



Il existe 4 approches pour déterminer le type de schéma :


- Méthode du profil (graphique)
- Méthode de la bande
- Méthode analytique ou test de Buys-Ballot
- Test log-level






**Méthode du profil (graphique)** : on superpose les saisons représentées par des courbes de profil sur un même graphique.

Si ces courbes sont parallèles, le modèle est additif, autrement le modèle est multiplicatif



**Méthode de la bande** : on fait un graphique représentant la série chronologique, puis on trace une droite passant respectivement par les minima et par les maxima de chaque saison.

Si ces deux droites sont parallèles, nous sommes en présence d'un modèle additif.  
Dans le cas contraire, c'est un modèle multiplicatif.  
(attention à prendre une période sans changement de tendance)



**Méthode analytique ou test de Buys-Ballot** : on teste si les moyennes et les écarts-types sont indépendantes.

On calcule les moyennes et les écarts-types pour chacune des périodes considérées puis la droite des moindres carrées

$$\sigma = a\bar{x} + b$$

- Si  $a = 0$  significativement  $\Rightarrow \sigma$  et  $\bar{x}$  indépendants  $\Rightarrow$  modèle additif
- Si  $a \neq 0$  significativement  $\Rightarrow \sigma$  et  $\bar{x}$  dépendants  $\Rightarrow$  modèle multiplicatif

date	2013	2014	2015	2016	2017
janvier	124384	125125	132815	138050	152708
février	142556	140717	147060	166230	161374
mars	164448	178758	195362	209981	224936
avril	154407	164400	168144	180746	169342
mai	144078	144988	139957	171731	187481
juin	182245	187756	216465	217289	220196
juillet	144303	138048	141489	128370	143062
août	82157	80669	88984	95114	104626
septembre	140652	149766	163328	167466	169077
octobre	165992	159789	161254	154689	176078
novembre	137993	134223	148972	162082	179075
décembre	173736	161616	182403	192725	191556
moyenne	146412.6	147154.6	157186.1	165372.8	173292.6
écart-type	26191.5	27834.2	32669.6	34234.8	32573.2
a =	0.25				
b =	-9135.47				

**Test log-level** : les méthodes X13-ARIMA, TRAMO-SEATS et X13-SEATS-ARIMA proposent une procédure de pré-test pour tester la spécification log-level.

Ils comparent le critère AICc de l'estimation du maximum de vraisemblance d'une transformation Box-Cox avec

- $\lambda = 0$  : transformation en logs  $\Rightarrow$  décomposition multiplicative
- $\lambda = 1$  : transformation en niveau (*level*)  $\Rightarrow$  décomposition additive

$$B(X_t, \lambda) = \begin{cases} \frac{X_t^\lambda - 1}{\lambda} & \text{si } \lambda \neq 0 \\ \log(X_t) & \text{si } \lambda = 0 \\ X_t & \text{si } \lambda = 1 \end{cases}$$

L'utilisateur peut choisir dans le package **seasonal** entre

- pas de transformation : `transform.function = "none"`
- transformation logarithmique : `transform.function = "log"`
- test la spécification log-level (option de défaut)

La fonction `out` du package `seasonal` affiche le contenu de la sortie principale du X-13 dans le navigateur

```
library(seasonal)
seasX <- seas(yy)
out(seasX)
```

Reading input spec file from C:\Users\darne-o\AppData\Local\Temp\Rtmpy2RVq5\x13out8c8076f328eb\iofile.spec

Reading data from C:\Users\darne-o\AppData\Local\Temp\Rtmpy2RVq5\x13out8c8076f328eb\data.dta

[Previous Table](#) | [Index](#) | [Next Table](#)

## U. S. Department of Commerce, U. S. Census Bureau

### X-13ARIMA-SEATS monthly seasonal adjustment Method, Release Version 1.1 Build 39

This software application provides an enhanced version of Statistics Canada's X-11-ARIMA extension (Dagum, 1980) of the X-11 variant of the Census Method II of Shiskin, Young and Musgrave (1967).

It also provides an ARIMA model-based method following Hillmer and Tiao (1982) and Burman (1980) that is very similar to the update of the method of SEATS (Gómez and Maravall, 1996) produced at the Bank of Spain by G. Caporello and A. Maravall for TSW (Caporello and Maravall, 2004). The present application includes additional enhancements.

X-13ARIMA-SEATS includes an automatic ARIMA model selection procedure based largely on the procedure of Gómez and Maravall (1998) as implemented in TRAMO (1996) and subsequent revisions.

Primary Programmers: Brian Monsell, Mark Otto and,  
for the ARIMA model-based signal extraction,  
Giulinea Caporello and Victor Gómez

### Index for x13out8c8076f328eb\iofile.ht

- Program Reader
- File Name Requests
- Links to other HTML files
- Content of input specification file
- AIC test for transformation
- A 1 Time series data (for the spec analyzed)
- Automatic ARIMA model selection
- Regression model
- ARIMA model
- Maximized log-likelihood and model selection criteria
- Diagnostic Checking
- Residual autocorrelations
- Plot of Residual autocorrelation
- Squared residual autocorrelations
- Plot of Squared residual autocorrelations
- Plot of Histogram of the resARIMA residuals
- Tabular Histogram of the Residuals
- Normality statistics for resARIMA residuals
- Durbin-Watson statistic for model residuals
- Friedman non-parametric test for residual seasonality
- QS Statistics for resARIMA Model Residuals
- Plot of Spectrum of the resARIMA model residuals
- Forecasting
- A & B ResARIMA combined output
- B 1 Overall series (prior adjusted)
- SEATS Part 1 - ARIMA estimation
- Overall uncorrected series (from resARIMA)
- Pre-determined factors series and other determinate effects
- ARIMA series (corrected by resARIMA)
- SEATS model parameters
- Diagnostics

## Likelihood statistics for model fit to untransformed series.

Likelihood Statistics	
Number of observations (nobs)	264
Effective number of observations (nefobs)	251
Number of parameters estimated (np)	3
Log likelihood (L)	-1192.3287
<u>AIC</u>	2390.6574
<u>AICC</u> (F-corrected-AIC)	2390.7546
Hannan Quinn	2394.9136
<u>BIC</u>	2401.2338

## Likelihood statistics for model fit to log transformed series.

Likelihood Statistics	
Number of observations (nobs)	264
Effective number of observations (nefobs)	251
Number of parameters estimated (np)	3
Log likelihood	793.2709
Transformation Adjustment	-1991.9574
Adjusted Log likelihood (L)	-1198.6865
<u>AIC</u>	2403.3730
<u>AICC</u> (F-corrected-AIC)	2403.4702
Hannan Quinn	2407.6292
<u>BIC</u>	2413.9494

\*\*\*\*\* AICC (with aicdiff=-2.00) prefers **no transformation** \*\*\*\*\*

## La désaisonnalisation

La *désaisonnalisation* ou *correction des variations saisonnières* (CVS) ou *ajustement saisonnier* (seasonal adjustment, SA) a pour objectif d'éliminer les composantes saisonnières des séries temporelles économiques afin de mettre en évidence les autres éléments (tendance et cycle) qui jouent un rôle important dans l'analyse économique.

La série *désaisonnalisée* ou *corrigées des variations saisonnières* (CVS) est définie par

$$SA_t = TC_t + I_t$$

La série *CVS et corrigée des jours ouvrables* (CVS-CJO) est définie par

$$SA_t = TC_t + I_t - WD_t$$

L'idée d'identifier et de supprimer la saisonnalité dans les chroniques est très ancienne, et remonte au XIXème siècle. En effet, Jevons (1862) préconise

*Chaque type de fluctuations périodiques, qu'elles soient journalières, hebdomadaires, trimestrielles ou annuelles, doit être détecté. [...] En effet, nous devons établir et éliminer de telles variations périodiques avant de pouvoir correctement montrer celles qui sont irrégulières et non périodiques, et qui probablement présentent plus d'intérêt et d'importance.*



William Stanley Jevons  
économiste anglais  
(1835-1882)



D'après Hylleberg (1992), le problème de la désaisonnalisation se produit dans au moins deux contextes économiques différents :

- les **études historiques des cycles d'affaires** (Burns et Mitchell, 1946 ; Kaiser et Maravall, 2000)
- l'**évaluation des conditions économiques actuelles ou conjoncturelles** : analyse des phases récentes de récession et d'expansion de l'activité économique (Moore, 1961 ; Dagum, 2001)

Hylleberg souligne également que l'utilisation de l'analyse économétrique sur des données désaisonnalisées augmente le risque d'une mauvaise spécification du modèle, entraînant ainsi des relations dynamiques fallacieuses et de faibles prévisions (tests de racines unitaires et de cointégration saisonnières)

Néanmoins, la plupart des modèles macro-économétriques emploient des données **corrigées des variations saisonnières** (CVS) produites par les agences de statistique.

Un certain nombre de méthodes de désaisonnalisation sont apparues dans les années 20 et 30, mais c'est principalement depuis l'essor de l'informatique après la seconde guerre mondiale qu'elles se sont développées.

De nombreuses recherches se sont intéressées à la correction des variations saisonnières présentes dans les données sans toutefois en modifier les caractéristiques.

Cette opération est délicate, ce qui explique le développement de diverses méthodes dont le but est d'améliorer l'ajustement saisonnier.

## Approches temporelle et fréquentielle

Une série temporelle peut être considérée de deux points de vue : celui du temps et celui des fréquences

- Dans le **domaine temporel**, on regarde la série  $\{X_t\}$  comme une succession de  $T$  valeurs observées aux instants  $t$ , avec  $t = 1, \dots, T$
- Dans le **domaine des fréquences**, on part de l'expression de la série  $\{X_t\}$  comme une somme de fonctions sinusoïdales. On mesure alors pour chaque fréquence, l'importance qu'elle a dans la composition de la série

Ces deux approches s'avèrent souvent complémentaires

**Approche temporelle** : il est facile de représenter graphiquement son évolution au cours du temps. On note que cette série est caractérisée par une forte saisonnalité traduisant la chute de l'activité industrielle au mois d'août

Les modélisations de la série, ou de ses composantes, mettant en relation la valeur à l'instant  $t$  et celles des instants passés sont facile à formaliser.

C'est le cas par exemple de la modélisation de la série par un modèle ARIMA saisonnier (SARIMA), de l'expression d'une tendance linéaire, exponentielle ou encore localement polynomiale, ou de la modélisation de la composante irrégulière par un bruit blanc.




FIG. 3.1 – Indice mensuel de la production industrielle en France, d'octobre 1985 à mars 1995.

**Approche fréquentielle** : le spectre de la série associe à chaque fréquence son importance dans la série. Le spectre de l'indice de la production industrielle laisse apparaître une forte contribution (pic spectral) de la fréquence  $\pi/6 = 30^\circ$ , et de ses multiples  $2\pi/6 = 60^\circ$ ,  $3\pi/6 = 90^\circ$ ,  $\dots$ ,  $6\pi/6 = 180^\circ$ .

La période associée à cette fréquence est  $\omega = 2\pi/f = 2\pi/(\pi/6) = 12$ , et nous retrouvons la saisonnalité mensuelle observée sur la graphique précédent.

Les basses fréquences correspondent par nature à des composantes évoluant lentement, tendance et cycle par exemple, et les hautes fréquences à des composantes évoluant plus vite comme la composante irrégulière.






FIG. 3.2 – Spectre de l'indice de la production industrielle française.

Le **périodogramme** permet de représenter l'évolution des séries dans le domaine des fréquences : package **TSA**

```
library(TSA)
y <- read.table("c://R//data//demandbrut.txt")
yy <- ts(data = y, start=c(1996,01),frequency=12)
periodogram(yy)
```



série originale



série en différence 1ère

Les procédures sont généralement classées en trois catégories :


- les **méthodes non paramétriques** (ou **modèles implicites**) fondées sur des filtres de lissage linéaire où les variables inobservables sont modélisées de manière **implicite**
- les **méthodes paramétriques** (ou **modèles explicites**) pour lesquelles les composantes inobservables sont modélisées et estimées **explicitement**
  - les **méthodes paramétriques déterministes** où chaque composante a un comportement « déterministe » dans le sens de la décomposition de Wold (1938) représentée par des modèles de régression
  - les **méthodes paramétriques stochastiques** basée sur des comportements « stochastiques » ou « purement linéaires » en utilisant des modèles univariés de type ARIMA (*Autoregressive Integrated Moving Average*)
- les **méthodes semi paramétriques** (ou **modèles mixtes**) basées sur des modèles hybrides (combinant des modèles implicites et explicites)

## 1. Les méthodes non paramétriques (modèles implicites)

En matière de désaisonnalisation des séries économiques, les [filtres de lissage linéaire](#) ou [moyennes mobiles](#) sont déjà connus au début des années 20, mais sont rarement utilisés.

L'instrument le plus utilisé à l'époque pour éliminer la composante saisonnière mensuelle était la [moyenne mobile centrée d'ordre 12](#)





La **moyenne mobile centrée d'ordre 12** s'avère un piètre estimateur de la tendance-cycle :

- cette moyenne ne peut pas suivre avec précision les sommets et les creux des cycles conjoncturels à court terme (d'une périodicité de 5 ans ou plus)
- à moins que les fluctuations accidentelles aient une faible amplitude, elle ne comprend pas suffisamment de termes pour assurer un lissage adéquat des données
- les moyennes mobiles sont très sensibles aux cas erratiques (points atypiques, *outliers*) et nécessitent de ce fait un traitement *a priori* des valeurs extrêmes

Vers la fin des années 20, l'élaboration de **nouveaux filtres de lissage et de techniques d'application différentes** permet de diffuser cette approche non paramétrique pour la désaisonnalisation des séries temporelles économiques (Macaulay, 1931)

Progressivement, les gouvernements et les bureaux de statistique commencent à appliquer les procédés de lissage pour désaisonnaliser leurs séries, mais la méthode est coûteuse, longue et subjective, parce que les ajustements sont réalisés, pour la plupart, à la main.

Le développement de l'informatique, après la seconde guerre mondiale, contribue à la propagation et à l'amélioration des méthodes non paramétriques de désaisonnalisation.

La méthode la plus connue est sûrement la **méthode X-11** (Shiskin, Young et Musgrave, 1967).


Par la suite, de nombreuses méthodes dont le principe de construction est identique à celui de X-11 ont été développées et sont appelées « **style X-11** »

## Les moyennes mobiles

Ces outils font partie des premières méthodes pour l'analyse des séries chronologiques. Il semble que le physicien [John Henry Poynting](#) soit le premier, en 1884, à avoir utilisé les moyennes mobiles pour éliminer les variations accidentelles ou périodiques d'une série.

En 1904, [Spencer](#) introduit une moyenne mobile (symétrique d'ordre 15) permettant de conserver les polynômes de degré 3.

Puis à partir de 1914, les grands personnages de la statistique tels que [Karl Pearson](#) et [George Yule](#) par exemple, s'intéressent à ce genre de problèmes.



John Henry Poynting  
physicien anglais



Karl Pearson  
mathématicien britannique  
(1857 -1936)

Karl Pearson  
mathématicien britannique



George Yule  
mathématicien britannique  
(1871 -1951)

George Yule  
mathématicien britannique

## Définition

Une **moyenne mobile** (*moving average*) de **coefficients**  $\theta_i$ , noté  $M(\theta_i)$  ou  $M$ , est un opérateur linéaire du type

$$M = \sum_{i=-p}^f \theta_i L^{-i} = \sum_{i=-p}^f \theta_i F^i$$

- $p$  et  $f$  sont 2 entiers positifs
- $\theta_{-p}, \dots, \theta_{-1}, \theta_0, \theta_1, \dots, \theta_f$  : **coefficients de  $M$**  (nombres réels)
- $L$  : **opérateur de retard** (*backward*)  $L^p X_t = X_{t-p}$ , avec  $L^0 = 1$
- $F$  : **opérateur d'avance** (*forward*)  $F = L^{-1}$
- **ordre de la moyenne mobile  $M$**  :  $p + f + 1$  (nombre de coefficients)
- une moyenne mobile  $M$  est **centrée** si  $f = p$
- une moyenne mobile  $M$  est **symétrique** si  $M$  est centrée et si  $\theta_i = \theta_{-i}$
- moyenne mobile centrée est automatiquement d'ordre impair :  
 $p + f + 1 = 2p + 1$

Pour une série chronologique  $X_t$  une moyenne mobile en  $t$  est une **combinaison linéaire finie** des valeurs de la série correspondant à des dates entourant  $t$ , elle réalise donc un lissage de la série, une moyennisation

$$\begin{aligned}M(X_t) &= \sum_{i=-p}^f \theta_i X_{t+i} = \theta_{-p} X_{t-p} + \cdots + \theta_{-1} X_{t-1} + \theta_0 X_t + \theta_1 X_{t+1} + \cdots + \theta_f X_{t+f} \\&= \sum_{i=-p}^f \theta_i L^i X_t = \theta(L) X_t\end{aligned}$$

- pour une série temporelle on doit avoir :  $p+1 \leq t \leq T-f$

## Propriétés

- $M$  **conserve**  $X_t$  ou  $X_t$  est **invariante** par  $M$  si  $M(X) = X$
- $X_t$  est **absorbée** par  $M$  si  $M(X) = 0$

## Propriétés : préservation de la tendance

- une moyenne mobile  $M$  centrée **conserve** les suites constantes ssi

$$\sum_{i=-p}^p \theta_i = 1$$

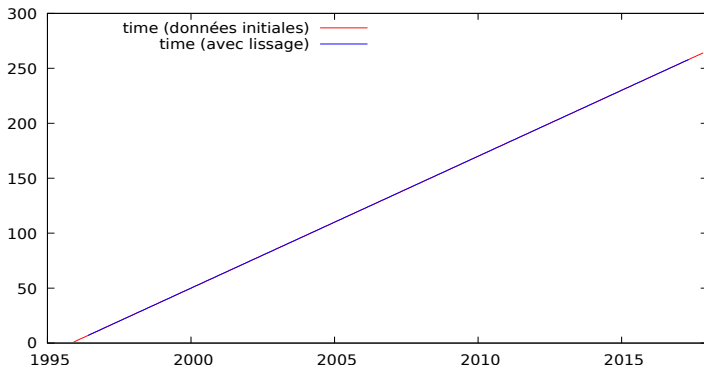
- si  $M$  est symétrique et conserve les constantes, alors  $M$  **conserve** les polynômes de degré 1 (i.e  $X_t = at + b$ ) ssi

$$\sum_{i=-p}^p \theta_i = 1 \quad \text{et} \quad \sum_{i=-p}^p i\theta_i = 0$$

- une moyenne mobile  $M$  centrée **conserve** tout polynôme de degré  $d$  ssi ses coefficients vérifient

$$\sum_{i=-p}^p \theta_i = 1 \quad \text{et} \quad \sum_{i=-p}^p i^h \theta_i = 0 \quad 1 \leq h \leq d$$

Figure: Moyenne mobile centrée à 12 termes sur une tendance linéaire





## Les moyennes mobiles arithmétiques

Pour éliminer la saisonnalité, les **moyennes mobiles d'ordre  $k$**  permettent d'éliminer la **saisonnalité de période  $k$** .

### Définition

Une **moyenne mobile arithmétique  $M$  d'ordre impair  $k = 2p + 1$**  est définie par  $\theta_i = \frac{1}{(2p+1)}, \forall i = -p, \dots, p$ :

$$M(X_t) = \frac{1}{2p+1} \sum_{i=-p}^p X_{t+i}$$

### Propriété

Une **moyenne mobile arithmétique d'ordre impair  $2p + 1$**  absorbe les saisonnalités de périodes  $k = 2p + 1$  qui sont nulles en moyenne, et elle préserve les polynômes de degré 1

Toutefois, en pratique, il est souvent nécessaire de considérer des **saisonnalités de période paire** (données trimestrielles ou mensuelles).

Pour cela, si la période est  $k = 2p$ , on utilise la moyenne mobile  $M = \frac{1}{2}M_1 + \frac{1}{2}M_2$

$$M_1 = \frac{1}{2p} \sum_{i=-p}^{p-1} X_{t+i} = \frac{1}{2p} (X_{t-p} + \cdots + X_{t+p-1})$$

$$M_2 = \frac{1}{2p} \sum_{i=-p+1}^p X_{t+i} = \frac{1}{2p} (X_{t-p+1} + \cdots + X_{t+p})$$


Les moyennes mobiles  $M_1$  et  $M_2$  absorbent les saisonnalités de période  $2p$  et de moyenne nulle mais elles ne sont pas symétriques

## Définition

**La moyenne mobile arithmétique  $M$  d'ordre pair  $k = 2p$  est **symétrique**, **annule** les saisonnalités de période  $2p$  et de moyenne nulle, et **préserve** les polynômes de degré 1**

$$\begin{aligned} M(X_t) &= \frac{1}{2p} \left( \frac{X_{t-p}}{2} + \sum_{i=-p+1}^{p-1} (X_{t+i}) + \frac{X_{t+p}}{2} \right) \\ &= \frac{1}{2p} \left( \frac{X_{t-p}}{2} + X_{t-p+1} + \cdots + X_{t+p-1} + \frac{X_{t+p}}{2} \right) \end{aligned}$$

Figure: Moyenne mobile centrée à 12 termes



## Les moyennes mobiles simples composées

Une moyenne mobile dite  $P \times Q$ , notée  $M_{P \times Q}$  s'obtient en composant

- une moyenne mobile simple d'ordre  $P$ , de coefficients tous égaux à  $1/P$
- une moyenne mobile simple d'ordre  $Q$ , de coefficients tous égaux à  $1/Q$
- cela revient à appliquer successivement à la série les deux moyennes mobiles simples

Une moyenne mobile  $M_{P \times Q}$  est une **moyenne mobile symétrique d'ordre  $P + Q + 1$**

Quelques exemples de moyennes mobiles  $M_{P \times Q}$

- Estimation de la tendance-cycle  $TC_t$  :  $M_{2 \times 12}$
- Estimation de la saisonnalité  $S_t$  :  $M_{3 \times 3}$ ,  $M_{3 \times 5}$  ou  $M_{3 \times 9}$

NB : voir en annexe l'expression sous forme de polynome de la moyenne mobile centrée à 12 termes  $M_{2 \times 12}$

## Effet d'une moyenne mobile sur les fluctuations irrégulières

Par construction, une moyenne mobile consiste à un **lissage** de la série.


L'effet de la composante irrégulière est d'autant plus atténué que l'ordre de la moyenne mobile est grand

Les moyennes mobiles arithmétiques d'ordre  $k = 2p + 1$  sont les moyennes mobiles **minimisant la variance** d'un bruit blanc parmi les moyennes mobiles centrées telles que

$$\sum_{i=-p}^p \theta_i = 1$$

Ainsi les moyennes arithmétiques d'ordre  $k = 2p + 1$  transforment un bruit blanc en un processus **centré** (inchangé) et de variance  $\sigma^2 / (2p + 1)$  **réduite**

Figure: Moyenne mobile arithmétique à 13 termes sur la composante irrégulière



	Moyenne	Médiane	S.D.	Min	Max
resid	0.1124	0.09426	0.9876	-2.173	3.017
ma_resid	0.09331	0.1289	0.2747	-0.6597	0.6358

## La méthode X-11

En 1954, Julius Shiskin met au point une méthode (*Method I*) au US Bureau of the Census .

Cette technique de désaisonnalisation est suivie par 11 versions eXpérimentales d'une *Method II* (X0, X1, etc) pour finalement aboutir au [logiciel X-11](#) en 1965 (Shiskin, Young et Musgrave, 1967).

Inspirées directement des lissages par moyennes mobiles et des travaux de Macaulay (1931), ces diverses versions constituent les [premières méthodes automatiques de désaisonnalisation](#) et X-11 devient rapidement un standard utilisé dans le monde entier.



La **méthode X-11** est basée sur l'utilisation de différentes sortes de **moyennes mobiles symétriques et asymétriques** pour décomposer une série temporelle en ses éléments de tendance, saisonnier et irrégulier, sans modèle explicite sous-jacent.

Les estimations des composantes saisonnière et de tendance résultent d'un **filtrage en cascade**, cad de l'application successive de divers filtres linéaires individuels, appliqués de manière séquentielle. Chaque composante s'obtient après plusieurs itérations

Pour des données mensuelles, ce filtrage est composé de :

- une moyenne mobile centrée à 12 termes
- deux moyennes mobiles saisonnières d'ordre  $3 \times (2p + 1)$ , et
- une moyenne mobile de Henderson : **estimation lisse** (*smooth*) de la tendance-cycle (voir annexe)
- pour les observations en début et en fin de série, X-11 emploie des **moyennes mobiles asymétriques** dérivées de la méthode de Musgrave (1964) afin de prolonger la série (voir annexe)

*L'algorithme de la méthode X-11 est présenté en annexe*

## Avantage

- La force principale du logiciel X-11 vient de son application massive dans les organismes et les instituts de statistique nationaux et internationaux durant des années, ce qui a permis de l'enrichir avec des mises à jour régulières.

## Inconvénients

- Son inconvénient majeur a été une estimation peu fiable des valeurs désaisonnalisées en fin de série (application des filtres asymétriques  $\Rightarrow$  révisions importantes lorsque de nouvelles observations sont disponibles).
- Ces valeurs en fin de série sont importantes pour évaluer la direction de la tendance de court terme et identifier un point de retournement cyclique dans l'économie.
- En outre, les tests statistiques étaient peu nombreux et les indicateurs pour évaluer la qualité de la désaisonnalisation étaient absents.

Solution : méthodes semi-paramétriques X11-ARIMA

Par la suite, de nombreuses méthodes dont le principe de construction est identique à celui de X-11 ont été développées et sont appelées « **style X-11** »

- La **méthode SABL** (*Seasonal Adjustment at Bell Laboratories*), développée par Cleveland, Dunn et Terpenning (1978) à Bell Laboratories
- La **méthode SEASABS** (*SEASonal Analysis at Australian Bureau of Statistics*), développée par l'Australian Bureau of Statistics (1987)
- Le **logiciel GLAS** (*General Linear Abstraction of Seasonality*), développé par Young (1992) à la Banque d'Angleterre
- Le **logiciel STL** (*Seasonal-Trend decomposition based on Loess*, proposé par Cleveland *et alii* (1990) à Bell Laboratories  
Le package **stats** avec la fonction **stl** ou le package **stlplus** décompose la série à partir de l'**approche STL**

## La méthode STL

Dans la **méthode STL** (*Seasonal-Trend decomposition based on Loess*), proposée par Cleveland *et alii* (1990), chaque composante est déterminée par une **régression locale** (Cleveland, 1979, 1981 ; Cleveland et Devlin, 1988), aussi appelée :

- **lissage LOESS** (*LOcally Estimated Scatterplot Smoothing*) ou
- **lissage LOWESS** (*LOcally WEighted Scatterplot Smoothing*)

C'est une **méthode non paramétrique**, appelée aussi **régression polynomiale locale, avec pondération locale**, basée sur la méthode des  **$k$  plus proches voisins** ( $k$ -NN, *k-nearest neighbors*, méthode d'apprentissage supervisé).

La procédure est la suivante :

- Pour chaque valeur  $x$  d'une série  $X$ , on va considérer les  $k$  plus proches voisins à gauche et à droite notées  $x_i$  ( $k$ -NN)
- La distance locale maximale est calculée parmi les  $k$ -NN :

$$\lambda(x) = \max_i |x_i - x|$$

- Des poids sont attribués à chaque point du voisinage  $k$ -NN  $x_i$  :

$$\omega_i(x) = W\left(\frac{|x_i - x|}{\lambda(x)}\right)$$

avec  $W(\cdot)$  une fonction de poids cubique :

$$W(u) = \begin{cases} (1 - u^3)^3 & \text{pour } 0 \leq u < 1 \\ 0 & \text{pour } u \geq 1 \end{cases}$$

Les  $x_i$  proches de  $x$  auront les poids les plus importants

Les poids décroissent lorsque  $x_i$  s'éloigne de  $x$  et deviennent nuls au  $k$ -ième point le plus éloigné

- Ensuite, un polynôme de degré  $d$  est ajusté aux données avec les poids  $\omega_i(x)$ 
  - soit un polynôme de degré  $d = 1$  (localement linéaire)
  - soit un polynôme de degré  $d = 2$  (localement quadratique)
  - le degré  $d = 0$  revient à calculer des moyennes mobiles pondérées

## 2. Les méthodes semi-paramétriques (modèles hybrides)

La vulgarisation des **modèles ARIMA** (*AutoRegressive Integrated Moving Average*) à partir de l'ouvrage de Box et Jenkins (1970) a permis de faire progresser les outils de désaisonnalisation.

⇒ évolution de la méthode X-11 vers la famille des méthodes de type **X11-ARIMA**, en améliorant notamment l'estimation des **observations récentes** (défaut majeur de X-11) sous forme de logiciel :

- **X11-ARIMA/80** par Dagum (1980) à Statistique Canada
- **X12-ARIMA** par Findley et alii (1988, 1998) au US Bureau of the Census
- **X13-ARIMA-SEATS** par Monsell et alii (2013) au US Bureau of the Census

La série initiale  $X_t$  est modélisée par un processus ARIMA saisonnier (SARIMA) puis prolongée en début et en fin de série, limitant ainsi **les révisions des estimations** lorsque l'on dispose d'une observation supplémentaire.

Cette approche permet ainsi de prévoir jusqu'à **trois années de données supplémentaires**

Néanmoins, il faut noter que les modèles ARIMA ne peuvent pas être appliqués directement sur les séries économiques sans une analyse préalable de celles-ci, notamment à cause

- du problème de stationnarité
- des effets déterministes (effets de calendriers, outliers ...)

Un module de **pré-traitement** des données, appelé RegARIMA (*Regression ARIMA*) a été développé, permettant une estimation simultanée des **points aberrants** (*outliers*), des **variations de jours ouvrables** et des **effets de calendrier**, avec un **modèle SARIMA**.

La procédure de sélection du modèle SARIMA dans la version de la [méthode X-13ARIMA-SEATS](#), à travers le module [RegARIMA](#), utilise l'[algorithme de Hannan et Rissanen \(1982\)](#) dont l'avantage est sa rapidité de calcul.

Le module RegARIMA (idem TRAMO) impose des [contraintes sur les polynômes](#) des modèles  $SARIMA(p, d, q)(P, D, Q)_S$  avec

- les polynômes non saisonniers :  $p, q \leq 3$
- les polynômes saisonniers :  $P, Q \leq 1$
- les ordres de différentiation non saisonnier et saisonnier :  $d \leq 3$  et  $D \leq 2$

L'[algorithme de Hannan-Rissanen](#) est utilisée pour sélectionner les ordres des [polynômes non saisonniers](#)  $(p, q)$  les plus adaptés, ayant pour objectif la sélection d'un modèle [parcimonieux](#) et [équilibré](#) :

- parcimonieux : un petit nombre de paramètres avec un bon pouvoir explicatif
- équilibré : un modèle pour lequel l'ordre des polynômes AR et de différentiation est égal à celui du polynôme MA



L'algorithme de Hannan-Rissanen pour un modèle ARMA( $p, q$ ) suit les étapes suivantes :

- la procédure de Hannan-Rissanen opère sur une transformation stationnaire de la série originale  $\Rightarrow$  identification uniquement des paramètres AR et MA
- ajustement d'un modèle  $AR(m)$  où  $m > \max(p, q)$  sur  $X_t$ . Dans le module RegARIMA  $p_{\max} = q_{\max} = 3$  (idem module TRAMO)
- les résidus obtenus  $\hat{a}_k$  sont utilisés pour estimer les innovations du modèle ARMA  $a_t$

$$a_t = X_t - \sum_{k=1}^m \hat{a}_k X_{t-k}$$

- les paramètres  $p$  et  $q$  du modèle ARMA sont estimés à partir d'une régression linéaire des moindres carrés de  $X_t$  sur  $(X_{t-1}, \dots, X_{t-p}, a_{t-1}, \dots, a_{t-q})$
- une paire  $(p, q)$  est sélectionnée à partir du critère  $BIC_{p,q}$  (*Bayesian information criterion*) :

$$BIC_{p,q} = \log(\sigma_{p,q}^2) + \frac{(p+q)\log(n-d)}{n-d}$$

avec  $\sigma_{p,q}^2$  l'estimateur du maximum de vraisemblance de  $\sigma^2$ ,  $n$  le nombre d'observations, et  $d$  l'ordre de différenciation

## Automatic ARIMA Model Selection

Procedure based closely on TRAMO ,method of Gomez and Maravall (2000)  
"Automatic Modeling Methods for Univariate Series",  
A Course in Time Series (Edited by D. Pena, G. C. Tiao, R. S. Tsay),  
New York : J. Wiley and Sons

**Maximum order for regular ARMA parameters : 2**

**Maximum order for seasonal ARMA parameters : 1**

**Maximum order for regular differencing : 2**

**Maximum order for seasonal differencing : 1**

Results of Unit Root Test for identifying orders of differencing:

Regular difference order : 2 Seasonal difference order : 1

Mean is not significant.

Best Five ARIMA Models

Model # 1 : (0 2 1)(0 1 1) ( $BIC_2 = 9.313$ )

Model # 2 : (1 2 1)(0 1 1) ( $BIC_2 = 9.325$ )

Model # 3 : (0 2 2)(0 1 1) ( $BIC_2 = 9.326$ )

Model # 4 : (2 2 0)(0 1 1) ( $BIC_2 = 9.346$ )

Model # 5 : (2 2 1)(0 1 1) ( $BIC_2 = 9.347$ )

Preliminary model choice : (0 2 1)(0 1 1)

## ARIMA Model

ARIMA Model: (0 2 1)(0 1 1)

Nonseasonal differences: 2

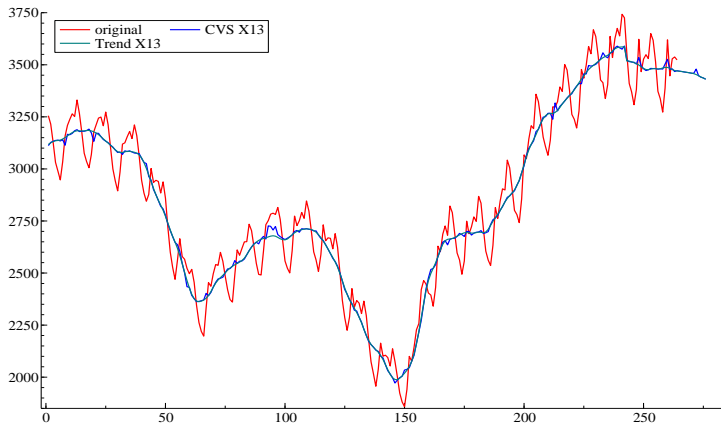
Seasonal differences: 1

ARIMA Model		
	Estimate	Standard Error
Nonseasonal MA		
Lag 1	0.69654	0.04526
Seasonal MA		
Lag 12	0.43662	0.05987

Model Innovation Variance	
Variance	0.59935E+03
Standard Error of Variance	0.53607E+02

[Previous Table](#) | [Index](#) | [Next Table](#)

Likelihood Statistics	
Number of observations (nobs)	264
Effective number of observations (nefobs)	250
Number of parameters estimated (np)	4
Log likelihood (L)	-1155.8212
AIC	2319.6425
AICC (F-corrected-AIC)	2319.8057
Hannan Quinn	2325.3116
BIC	2333.7283



## 3. Les méthodes paramétriques (modèles explicites)

Certains auteurs ont critiqué les approches non paramétriques de désaisonnalisation basées sur les filtres linéaires ou moyennes mobiles, cad des procédures « empiriques » *ad hoc* alors qu'il existe des outils mathématiques adéquats.

L'insatisfaction de ces méthodes conduit à l'utilisation de **modèles explicites** de séries temporelles pour la désaisonnalisation des séries

Deux types de méthodes se sont développées :

- les méthodes fondées sur des **modèles déterministes**
- les méthodes basées sur des **modèles stochastiques**

## Les méthodes déterministes

Ces **méthodes déterministes** supposent que chaque composante a un comportement « déterministe » dans le sens de la **décomposition de Wold** (1938), représentée par des **modèles de régression**

### Définition : Théorème de Wold

Il est toujours possible de décomposer un processus **stationnaire**  $X_t$  en

- une **composante déterministe**  $d_t$  (parfaitement prévisible) et
- une **composante stochastique**  $u_t$

telles que

$$X_t = d_t + u_t \quad \text{avec } u_t = \sum_{i=0}^{\infty} \alpha_i \varepsilon_{t-i}$$

où  $\varepsilon_t$  est un bruit blanc, cad moyenne nulle, variance constante et non autocorrélé.

Les **méthodes de régression** fournissent les premières **approches de désaisonnalisation basées sur le modèle** (AMB, *Model-Based Approaches*)

Ces méthodes s'appuient sur

- une modélisation de la série originale ( $X_t$ ) et de chacune des composantes ( $C_t$ ,  $T_t$ ,  $S_t$ ) par des fonctions paramétriques simples
- une estimation des paramètres par des méthodes de type MCO (OLS, *Ordinary Least Squares*)

A l'heure actuelle, cette approche ne suscite plus un grand intérêt car elle ne permet pas de prendre en compte les **propriétés stochastiques** des chroniques économiques.

## Les méthodes stochastiques

Les méthodes stochastiques sont fondées sur

- la spécification de **modèles ARIMA pour modéliser les composantes inobservables** (UCARIMA, *Unobserved Component ARIMA*)
- l'utilisation de la **théorie de l'extraction de signal**

Le problème de l'**extraction de signal** est d'estimer le signal  $S_t$  dans les observations

$$X_t = S_t + N_t$$

L'extraction de signal est utilisée en **désaisonnalisation** en identifiant :

- $S_t$  : élément saisonnier et
- $N_t$  : élément non saisonnier (le « bruit »)

et en modélisant convenablement  $X_t$ ,  $S_t$  et  $N_t$



On distingue deux approches :

- l'approche des séries temporelles structurelles (STS, *Structural Time Series*)
- l'approche basée sur le modèle ARIMA (AMB, *ARIMA Model-Based*).

## L'approche basée sur le modèle ARIMA (AMB)

L'approche AMB a pour objet de modéliser la série observée à partir d'un modèle ARIMA saisonnier (SARIMA) de manière à déduire les éléments à partir de la structure du modèle en utilisant les estimations spectrales

Puisque les composantes sont inobservables et afin d'obtenir une décomposition unique à partir du modèle ARIMA général ajusté à la série d'origine, Hillmer et Tiao (1982) proposent ce qu'ils appellent la décomposition canonique. Elle a les propriétés, entre autres,

- de maximiser la variance de la composante irrégulière
- de minimiser celle de la composante saisonnière

Les modèles ARIMA sont très sensibles aux **points atypiques** et ne peuvent pas estimer correctement les **éléments déterministes**.

Par conséquent, d'autres développements sont réalisés en combinant des **modèles de régression** avec des **variables dichotomiques** et des **erreurs ARIMA**.

C'est dans cette optique que le **logiciel TRAMO-SEATS** a été proposé.

## Le logiciel TRAMO-SEATS

Gómez et Maravall (1997) ont développé **TRAMO-SEATS** à la Banque d'Espagne

- **TRAMO** : *Time Series Regression with ARIMA Noise, Missing Observations, and Outliers*
- **SEATS** : *Signal Extraction in Arima Time Series*

L'application de **SEATS** suppose que la série soit **stationnaire** ou qu'elle puisse être stationnarisée afin d'être modélisée en utilisant des modèles SARIMA globaux.

Cette hypothèse de stationnarité est rarement justifiée pour les séries temporelles économiques.

Par conséquent, de la même manière que RegARIMA, le pré-programme **TRAMO** est utilisé pour

- rendre la série stationnaire
- supprimer les effets déterministes (effets de calendrier, outliers, ...)
- permettre l'estimation, la prévision et l'interpolation de modèles de régression avec des observations manquantes et des erreurs ARIMA, en présence de plusieurs types possibles de points atypiques

A partir de la [série linéarisée](#) par TRAMO, SEATS commence par ajuster un [modèle SARIMA](#).

Ce modèle est déterminé par une [procédure automatique d'identification de modèles](#), identique à RegARIMA, fondée sur

- des contraintes concernant les ordres des polynômes (saisonniers et non saisonniers)
- l'algorithme de Hannan-Rissanen pour les polynômes non saisonniers
- le critère d'information Bayésien (*Bayesian Information Criteria*, BIC)

Ensuite, SEATS utilise la [méthode AMB](#) pour décomposer la série en composantes de tendance-cycle, saisonnier et irrégulier.

## Définition

Un **modèle SARIMA** $(p, d, q)(P, D, Q)_s$  est défini de la manière suivante (Box et Jenkins, 1978)

$$\phi_p(B)\Phi_P(B^s)(1-B)^d(1-B^s)^D y_t = \theta_q(B)\Theta_Q(B^s)a_t$$

- $s$  : périodicité de la composante saisonnière
- $B$  : opérateur de retard tel que  $By_t = y_{t-1}$
- $\phi_p(B) = (1 - \phi_1 B - \dots - \phi_p B^p)$  : polynôme non saisonnier autorégressif (AR) d'ordre  $p$
- $\Phi_P(B^s) = (1 - \Phi_1 B^s - \dots - \Phi_P B^{Ps})$  : polynôme saisonnier autorégressif (SAR) d'ordre  $P$
- $\theta_q(B) = (1 - \theta_1 B - \dots - \theta_q B^q)$  : polynôme non saisonnier de moyenne mobile (MA) d'ordre  $q$
- $\Theta_Q(B^s) = (1 - \Theta_1 B^s - \dots - \Theta_Q B^{Qs})$  : polynôme saisonnier de moyenne mobile (SMA) d'ordre  $Q$
- $\Delta^d = (1 - B)^d$  : opérateur de différence (non saisonnière) d'ordre  $d$ -ième
- $\Delta_s^D = (1 - B^s)^D$  : opérateur de différenciation saisonnière d'ordre  $D$ -ième
- $\delta(B) = \Delta^d \Delta_s^D$  : opérateur de différenciation (filtres)
- $a_t$  : un **processus de bruit blanc**, normalement distribué de moyenne zéro et de variance  $\sigma_a^2$  :  $a_t \sim N(0, \sigma_a^2)$

Le **modèle SARIMA complet** peut se réécrire de la manière suivante :

$$\Psi(B)y_t = \pi(B)a_t + c$$

- $\Psi(B) = \phi_p(B)\Phi_P(B^s)(1-B)^d(1-B^s)^D$
- $\pi(B) = \theta_q(B)\Theta_Q(B^s)$
- $\Psi(B)$  et  $\pi(B)$  : **polynômes** respectivement **autorégressif** et de **moyenne mobile** satisfaisant les conditions de stationnarité et d'inversibilité
- $c = \Psi(B)\bar{y}$  avec  $\bar{y}$  la moyenne de  $y_t$

Le modèle pour la **série différenciée**  $z_t$  peut être exprimé de la manière suivante

$$\phi_p(B)\Phi_P(B^s)(z_t - \bar{z}) = \theta(B)a_t$$

- $z_t = \delta(B)y_t$  : processus stationnaire
- $\bar{z}$  : moyenne de  $z_t$

Le polynôme  $\Psi(B)$  est factorisé de la manière suivante :

$$\Psi(B) = \Psi_T(B)\Psi_S(B)\Psi_C(B)$$

où  $\Psi_T(B)$ ,  $\Psi_S(B)$  et  $\Psi_C(B)$  sont des polynômes autorégressifs qui contiennent respectivement les racines des composantes de tendance, saisonnière et cyclique.

On obtient ainsi :

$$y_t = \frac{\pi(B)}{\Psi(B)} a_t = \frac{\pi_T(B)}{\Psi_T(B)} a_{Tt} + \frac{\pi_S(B)}{\Psi_S(B)} a_{St} + \frac{\pi_C(B)}{\Psi_C(B)} a_{Ct} + u_t$$

- $u_t$  : un bruit blanc Gaussien
- les bruits  $a_{Tt}$ ,  $a_{St}$  et  $a_{Ct}$  sont non corrélés deux à deux.



Soit  $g_j(\omega)$  le spectre de  $[\pi(B)/\Psi(B)]a_t$ .

Si les spectres de toutes les composantes sont non négatifs, alors la **décomposition est dite admissible**

Les modèles pour les composantes de tendance, saisonnière et cyclique sont définies respectivement par :

$$\Psi_T(B)T_t = \pi_T(B)a_{Tt}$$

$$\Psi_S(B)S_t = \pi_S(B)a_{St}$$

$$\Psi_C(B)C_t = \pi_C(B)a_{Ct}$$

Il existe une infinité de décomposition admissible à partir d'un modèle SARIMA pour des composantes inobservables


Hillmer et Tiao (1982) proposent ce qu'ils appellent la **décomposition canonique** :

- mettre tout le bruit blanc dans la composante irrégulière
- maximiser la variance de l'irrégulier
- minimiser la variance de la composante saisonnière

L'application de la décomposition canonique permet d'obtenir une **décomposition unique** du modèle

Les paramètres des composantes de tendance-cycle ( $TC_t$ ) et saisonnière ( $S_t$ ) sont ensuite estimés par les estimateurs des erreurs moyennes quadratiques minimums (MMSE, *Minimum Mean Squared Error*), en utilisant le **filtre de Wiener-Kolmogorov**.

Figure: Décomposition de la série par TRAMO-SEATS via JDemetra+



## L'approche des séries temporelles structurales (STS)

L'approche STS consiste à spécifier directement des modèles ARIMA pour chaque variable inobservable.

Cette approche s'inscrit dans la continuité des méthodes de régression outre le fait qu'au lieu d'utiliser des modèles déterministes pour estimer chaque composante, elle emploie des modèles stochastiques simples appartenant à la classe ARIMA avec prédominance IMA (*Integrated Moving Average*).

La méthode de décomposition du modèle structurel est en 2 étapes (description est donnée en annexe) :

- 1 une **équation d'observation** (quelquefois appelée **équation de mesure**) composée d'éléments inobservables, cad la tendance-cycle, la saisonnalité et les irréguliers.  
Pour chaque variable inobservable, on suppose un modèle ARIMA très simple qu'on explicite avec des **équations dites d'état**.
- 2 Le **modèle structurel** est mis sous forme **d'espace d'état** et est souvent estimé par le filtre de **Kalman**

L'approche STS est implémentée dans des logiciels :

- Le module **STAMP** disponible dans OxMetrics
- Le package R **stats** avec la fonction `StrucTS`

## Le module STAMP

Koopman et alii (1995, 2010) ont développé le [logiciel STAMP](#) (*Structural Time series Analyser, Modeller and Predictor*) à la London School of Economics and Political Science.

STAMP, dans son option par défaut, suggère d'utiliser le [modèle structurel fondamental](#) (BSM, *Basic Structural Model*) proposé par Harvey (1981), cad un modèle sans élément exogène ni cycle, pour modéliser les composantes inobservables :

$$y_t = T_t + S_t + I_t$$

La **tendance** est modélisée comme une **marche aléatoire avec dérive**, où la dérive (la pente de la tendance) suit également une marche aléatoire.

$$\begin{aligned}T_t &= T_{t-1} + \beta_{t-1} + \eta_t \\ \beta_t &= \beta_{t-1} + \zeta_t\end{aligned}$$

- $\eta_t \sim N(0, \sigma_\eta^2)$  et  $\zeta_t \sim N(0, \sigma_\zeta^2)$  sont deux processus de bruit blanc mutuellement non corrélés
- si  $\sigma_\zeta^2 = 0 \Rightarrow$  processus  $I(1)$  :  $T_t = T_{t-1} + \beta_1 + \eta_t$
- si  $\sigma_\zeta^2 = 0$  et  $\sigma_\eta^2 = 0 \Rightarrow$  tendance linéaire :  $T_t = T_1 + \beta_1 t$

La **composante irrégulière** est généralement supposée être un **bruit blanc Gaussien** de moyenne zéro et de variance  $\sigma_\varepsilon^2$  :

$$I_t = \varepsilon_t \sim N(0, \sigma_\varepsilon^2)$$

Dans le BSM, la **composante saisonnière** est un modèle trigonométrique stochastique (Harvey, 1989) :

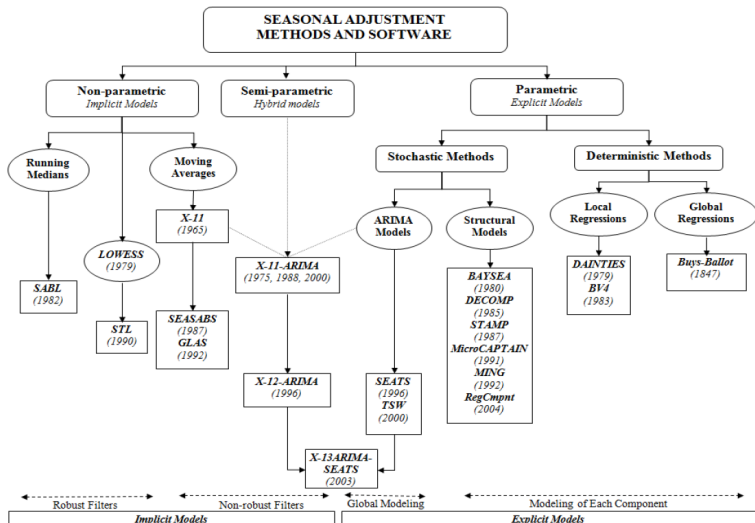
$$S_t = \sum_{j=1}^{[s/2]} \gamma_{j,t}$$

où chaque  $\gamma_{j,t}$  est générée par :

$$\begin{bmatrix} \gamma_{j,t} \\ \gamma_{j,t}^* \end{bmatrix} = \begin{bmatrix} \cos \lambda_j & \sin \lambda_j \\ -\sin \lambda_j & \cos \lambda_j \end{bmatrix} \begin{bmatrix} \gamma_{j,t-1} \\ \gamma_{j,t-1}^* \end{bmatrix} + \begin{bmatrix} \omega_{j,t} \\ \omega_{j,t}^* \end{bmatrix}$$

- $\lambda_j = 2\pi j/s$ ,  $j = 1, \dots, [s/2]$ ,  $s$  : le nombre d'observations par année, et  $t = 1, \dots, T$ .
- les innovations saisonnières  $\omega_{j,t}$  et  $\omega_{j,t}^*$  sont mutuellement non corrélées, de moyenne zéro et de variance commune  $\sigma_\omega^2$





## La détection des points atypiques

La présence de **point atypiques** (*outliers*) de nature transitoire ou permanent pose de nombreux problèmes d'estimation pour les méthodes de désaisonnalisation mais également pour les méthodes d'estimation (MCO), l'estimation des paramètres des modèles ARIMA ...

Les méthodes de désaisonnalisation actuelle proposent un **pré-traitement** de ces valeurs avant d'estimer les différentes composantes : TRAMO et RegARIMA.

Ces méthodes sont fondées sur les travaux de Box et Tiao (1975) sur l'**analyse d'intervention**.

Considérons une série temporelle univariée  $X_t$  décrite par un **modèle ARIMA** ( $p, d, q$ )

$$X_t = X_t^* + f(t) \quad (1)$$

$$\alpha(L)\phi(L)X_t^* = \theta(L)a_t \quad t = 1, \dots, T \quad (2)$$

$$f_t = \sum_i \omega_i \xi_i(L) I_t(\tau) \quad i = 1, \dots, 4 \quad (3)$$

- $X_t^*$  : modèle ARIMA( $p, d, q$ )
- $f(t)$  : processus contenant les points atypiques
- $L = B$  : opérateur retard
- $a_t$  : processus de bruit blanc  $a_t \sim N(0, \sigma_a^2)$
- $\alpha(L), \phi(L), \theta(L)$  : polynômes d'ordre respectifs  $d, p$  et  $q$
- $\xi_i(L)$  : polynôme caractérisant le point atypique qui se produit au temps  $t = \tau$
- $\omega_i$  : impact sur la série
- $I_t(\tau)$  : variable indicatrice (*dummy*) prenant la valeur de 1 au temps  $t = \tau$  et 0 sinon.

Il existe principalement 5 types de points atypiques, définis de la manière suivante :

- *Additive Outliers* (AO) : affectent une seule observation à un moment du temps dans la série temporelle

$$\xi_{AO} = 1$$

- *Level Shifts* (LS) : effet permanent sur le niveau de la série

$$\xi_{LS} = 1/(1 - L)$$

- *Temporary Changes* (TC) : effet temporaire la série qui retourne à son niveau précédent de manière exponentielle. Leur vitesse de retour dépend du paramètre  $\delta$  dans le polynôme





$$\xi_{TC} = 1/(1 - \delta L) \quad \text{avec } 0 < \delta < 1$$

- *Innovative Outliers* (IO) : impact sur les innovations du modèle

$$\xi_{IO} = \theta(L)/\alpha(L)\phi(L)$$

- *Seasonal Outliers* (SO) (ou *seasonal level shifts*, SLS) : effet permanent mais seulement sur une période particulière (ex. tous les mois de décembre)

$$\xi_{SO} = 1/\Delta_s$$



Les points atypiques sont identifiés lors d'une **procédure de détection séquentielle**, comprenant une itération interne et une autre externe

- dans l'itération externe, en supposant qu'il n'y a pas des points atypiques, un modèle ARIMA  $(p, d, q)$  est estimé, donnant ainsi les résidus
- les résultats de l'itération externe sont alors utilisés dans l'itération interne pour identifier les points atypiques
- les statistiques de test pour les 5 types de points atypiques,  $\hat{\tau}_i(\tau)$ ,  $i = 1, \dots, 5$ , sont calculées pour chaque observation
- si  $\hat{\tau}_{max} = \max|\hat{\tau}_i(\tau)| > VC \Rightarrow$  un point atypique est identifié au temps  $t = \tau$

Quand un outlier est détecté au temps  $t = \tau_1$  alors la **série est corrigée** de la manière suivante :


$$X_t^* = X_t - f(t)_{i^*}$$

La procédure est répétée jusqu'à plus aucun point atypique ne soit détecté


Ces détections et corrections de points atypiques sont mises en œuvre dans les **logiciels TRAMO** et **RegARIMA** (pré-ajustement de la série à modéliser)

*(détails de la procédure en annexe)*

**Figure:** Détection des outliers pour la série de la production industrielle par TRAMO et RegARIMA



**Figure:** Outliers dans les composantes de tendance et irrégulière par TRAMO-SEATS et X13-RegARIMA





Le package R [tsoutliers](#) permet de détecter les points atypiques en séries temporelles à partir de l'approche de Chen et Liu (1993), notamment les IO, A), LS, TC et SLS.

```
library(tsoutliers)
y <- read.table("c://R//data//demandcv.s.txt")
yy <- ts(data = y, start=c(1996,01),frequency=12)
tso(yy)
fit <- tso(yy)
plot(fit)
adj <- fit$yadj
write(t(adj),file="adjusted-series.out",ncolumn=1,append=FALSE)
```

Le package R [seasonal](#) permet de détecter les points atypiques à partir du module RegARIMA de la méthode X13-ARIMA-SEATS, basée sur la méthode améliorée de Chen et Liu (1993) par Gómez et Maravall (2001).

```
library(seasonal)
y <- read.table("c://R//data//demandcv.s.txt")
yy <- ts(data = y, start=c(1996,01),frequency=12)
seasX <- seas(yy)
# Linearized series or outlier-adjusted series: series.outlieradjorig or a19
adjseries = series(seasX, "a19")
```

Package R `tsoutliers` avec la fonction `tso`

```
Series: yy  
Regression with ARIMA(1,1,2) (1,0,1)[12] errors
```

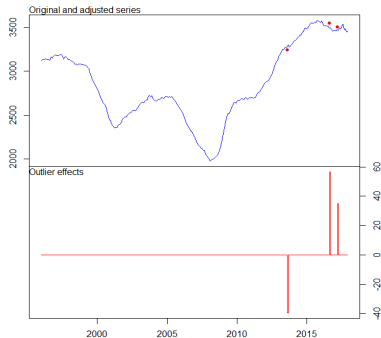
Coefficients:

	ar1	ma1	ma2	sar1	sma1	AO212	AO248	AO255
	0.9521	-0.7603	0.1996	0.5771	-0.8533	-39.3654	56.4502	35.0059
s.e.	0.0237	0.0649	0.0606	0.1233	0.0877	9.0728	9.8095	9.5972

```
sigma^2 estimated as 232.2: log likelihood=-1087.98  
AIC=2193.97 AICc=2194.68 BIC=2226.12
```

Outliers:

	type	ind	time	coefhat	tstat
1	AO	212	2013:08	-39.37	-4.339
2	AO	248	2016:08	56.45	5.755
3	AO	255	2017:03	35.01	3.647



Le package R `forecast` permet de détecter et corriger les points atypiques avec la fonction `tsclean` :

- cette méthode est basée sur décomposition à partir de la méthode STL
- la composante irrégulière (résidus) permet de détecter les outliers :  $\pm 2(Q_{0.9} - Q_{0.1})$
- les outliers détectés sont remplacés par interpolation linéaire pour les séries non saisonnières (ou désaisonnalisées par la méthode STL)

```
library(forecast)
y <- read.table("c://R//data//demandcv5.txt")
yy <- ts(data = y, start=c(1996,01),frequency=12)
tsoutliers(yy)
yyc <- tsclean(yy)
plot(yyc)
```

## Les logiciels de désaisonnalisation

Le logiciel **TRAMO-SEATS** est disponible sur le site de la Banque d'Espagne mais également dans des logiciels libres (Gretl) et commerciaux (EViews, SAS)

- **BdE :**

[https://www.bde.es/bde/en/secciones/servicios/Profesionales/Programas\\_estadi/Programas.html](https://www.bde.es/bde/en/secciones/servicios/Profesionales/Programas_estadi/Programas.html)

Le logiciel **X-13ARIMA-SEATS** est la dernière version du US Bureau of the Census, incorporant la méthode SEATS dans le logiciel de désaisonnalisation X-12-ARIMA. Il est également disponible dans des logiciels libres (Gretl, R) et commerciaux (EViews, SAS, Matlab)

- **Census :** <https://www.census.gov/srd/www/x13as/>

- **Interface R :** <https://cran.r-project.org/web/packages/seasonal/>

Le logiciel **JDemetra+** est une interface proposée par Eurostat et la Banque Centrale de Belgique, pour l'utilisation des méthodes TRAMO-SEATS et X-13ARIMA-SEATS

- **Eurostat :** <http://ec.europa.eu/eurostat/web/ess/-/jdemetra-officially-recommended-as-software-for-the-seasonal-adjustment-of-official-statistics>

Le package `seasonal` avec la fonction `seas` permet de décomposer la série à partir de X13ARIMA-SEATS

```
library(seasonal)
```

```
# By default, seas calls the SEATS adjustment procedure
```

```
# The X11 adjustment procedure: seasX11 <- seas(yy, x11 = "")
```

```
seasX <- seas(yy)
```

```
# Final CVS
```

```
final(seasX)
```

```
plot(seasX)
```

```
plot(irregular(seasX))
```

```
plot(trend(seasX))
```

```
summary(seasX)
```

```
Call:
```

```
seas(x = yy)
```

```
Coefficients:
```

	Estimate	Std. Error	z value	Pr(> z )
AO2013.Sep	54.32941	12.59425	4.314	1.60e-05 ***
MA-Nonseasonal-01	0.69654	0.04526	15.389	< 2e-16 ***
MA-Seasonal-12	0.43662	0.05987	7.293	3.04e-13 ***

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
SEATS adj.  ARIMA: (0 2 1)(0 1 1) Obs.: 264 Transform: none
```

```
AICc: 2320, BIC: 2334 QS (no seasonality in final): 0
```

```
Box-Ljung (no autocorr.): 39.04 * Shapiro (normality): 0.9792 ***
```

```
Messages generated by X-13:
```



```
Warnings:
```

```
- At least one visually significant trading day peak has been found in one or more of  
  the estimated spectra.
```

Time-Series demandeurs 1996 to 2017



Original and Adjusted Series



# Forecasting on 3 years

`series(seasX, "forecast.forecasts")`

# The `udg` function provides access to a large number of diagnostic statistics

`udg(seasX, "x13mdl")`

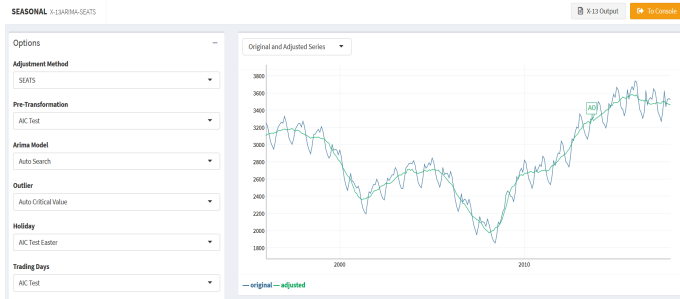
# The `out` function shows the content of the main output using the HTML version of X-13

`out(seasX)`

# The `view` function is a graphical tool for choosing a seasonal adjustment model

`install.packages("seasonalview")`

`view(seasX)`



## Analyse de la désaisonnalisation

A l'inverse de nombreux packages R le logiciel [JDemetra+](#) et le package proposent un grand nombre de diagnostics pour évaluer la qualité de la désaisonnalisation et de la décomposition de la série originale par [TRAMO-SEATS](#) et [X13-ARIMA](#)


- Pre-processing (Tramo ou Regarima)
  - Forecast
  - Regressors (outliers, trading days, easter effect ...)
  - Arima
  - Pre-adjustment series
  - Residuals
  - Likelihood
- Decomposition
- Benchmarking
- Diagnostics
  - Seasonality tests
  - Spectral analysis
  - Sliding spans (rolling-window estimation)
  - Revisions history
  - Model stability



Le package `stats` avec la fonction `decompose` permet de décomposer la série à partir de **moyennes mobiles**, avec des schémas additif ou multiplicatif

```
y <- read.table("c://R//data//demandbrut.txt")
yy <- ts(data = y, start=c(1996,01),frequency=12)
fit <- decompose(yy)
plot(fit)
show(yy)
```


**Decomposition of additive time series**




Le package `stats` avec la fonction `stl` et le package `stlplus` avec la fonction `stlplus` décomposent la série à partir de l'**approche STL** (*Seasonal-Trend decomposition based on Loess*) proposé par Cleveland et alii (1990)

```
y <- read.table("c://R//data//demandbrut.txt")
yy <- ts(y[1:264,1],frequency=12)
# NB: utile quand on a un message d'erreur avec ts() avec "univarié"
decomp <- stl(yy, s.window="per")
plot(decomp)
show(plot)
```

```
library(stlplus)
decomp <- stlplus(yy, s.window="per")
plot(decomp)
show(plot)
plot_trend(decomp)
tendance = trend(decomp)
```





Le package `stats` avec la fonction `StructTS` décompose la série à partir de l'**approche structurale des séries temporelles (STS)** (*Structural Time Series*) avec le modèle BSM


```
y <- read.table("c://R//data//demandbrut.txt")
yy <- ts(y[1:264,1],frequency=12)
fit <- StructTS(yy)
plot(cbind(fitted(fit), residuals(fit)))
show(fit)
```

Call:

```
StructTS(x = yy)
```

Variances:

level	slope	seas	epsilon
48.51	803.04	83.47	0.00



Le package `stR` avec la fonction `AutoSTR` décompose la série en utilisant une **procédure basée sur la régression** proposée par Dokumentov et Hyndman (2015) : STR (*Seasonal-Trend Decomposition Procedure Based on Regression*) :


$$y_t = T_t + S_t + I_t$$

- Smooth trend :  $\Delta^2 T_t = T_{t+1} - 2T_t + T_{t-1}$
- $S_t$  : composante saisonnière pouvant être fractionnaire, multiple, complexe
- $I_t \sim \mathcal{N}(0, \sigma_I^2)$

```
library(stR)
y <- read.table("c://R//data//demandbrut.txt")
yy <- ts(data = y, start=c(1996,01),frequency=12)
decomp <- AutoSTR(yy)
plot(decomp)
show(decomp)
```

Référence : Dokumentov et Hyndman (2015), STR: A Seasonal-Trend Decomposition Procedure Based on Regression





Le package `forecast` avec la fonction `tbats` décompose la série à partir d'un **modèle d'espace d'état avec lissage exponentiel et erreurs ARMA** proposé par De Livera, Hyndman et Snyder (2011) (cf. chapitre 3).

```
library(forecast)
y <- read.table("c://R//data//demandbrut.txt")
yy <- ts(data = y, start=c(1996,01),frequency=12)
decomp <- tbats(yy)
plot(decomp)
comp <- tbats.components(decomp)
```

Référence : De Livera, Hyndman et Snyder (2011), Forecasting Time Series With Complex Seasonal Patterns Using Exponential Smoothing

Decomposition by TBATS model




Figure: Séries CVS par R packages, Tramo-Seats, X13ARIMA et Stamp




Figure: Tendence-cycle par R packages, Tramo-Seats, X13ARIMA et Stamp




Figure: Composante saisonnière par R packages, Tramo-Seats, X13ARIMA et Stamp

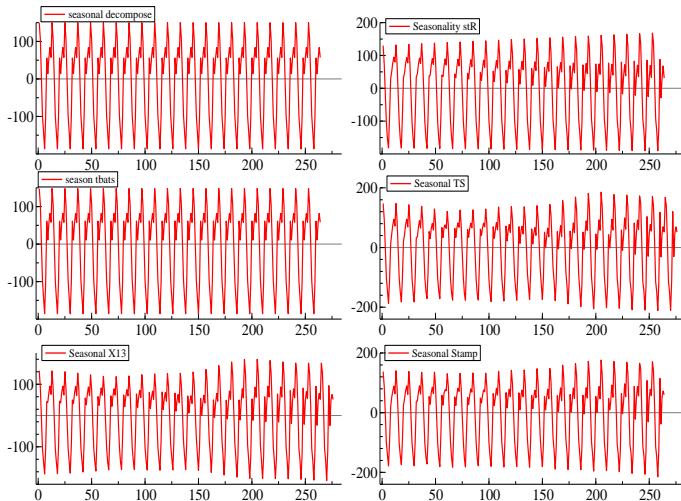



Figure: Composante irrégulière par R packages, Tramo-Seats, X13ARIMA et Stamp



## Les prévisions

Le package R `seasonal` permet de faire des **prévisions** sur 3 années (par défaut) à partir de la méthode X13-ARIMA-SEATS


```
library(seasonal)
y <- read.table("c://R//data//demandbrut.txt")
yy <- ts(data = y, start=c(1996,01),frequency=12)
seasX <- seas(yy)
fore = series(seasX, "forecast.forecasts")
# or
fore = series(seasX, "fct")
# one-ahead forecast
fore[1]
```

	forecast	lowerci	upperci
Jan 2018	3636.420	3588.4369	3684.403
Feb 2018	3603.655	3524.8252	3682.485
Mar 2018	3480.880	3370.6104	3591.149
Apr 2018	3339.444	3196.0490	3482.838
May 2018	3300.944	3122.4886	3479.399
Jun 2018	3233.297	3017.8063	3448.787
Jul 2018	3325.934	3071.4632	3580.406
Aug 2018	3551.805	3256.4597	3847.150
Sep 2018	3396.800	3058.7456	3734.853
Oct 2018	3468.845	3086.3112	3851.380
Nov 2018	3486.330	3057.5980	3915.062
Dec 2018	3462.927	2986.3357	3939.519




Parmi les R packages seul le package `forecast` permet de faire des **prévisions** avec la fonction `forecast` mais pour différentes approches comme avec la méthode TBATS

```
library(forecast)
y <- read.table("c://R//data//demandbrut.txt")
yy <- ts(data = y, start=c(1996,01),frequency=12)
fittbats <- tbats(yy)
# 6-ahead forecasts
prevtbats <- forecast(fittbats,12)
plot(prevtbats)
```



Le package `forecast` permet de faire des **prévisions** à partir de la méthode STS avec le modèle BSM

```
library(forecast)
y <- read.table("c://R//data//demandbrut.txt")
yy <- ts(data = y, start=c(1996,01),frequency=12)
fitsts <- StructTS(yy)
# 6-ahead forecasts
prevsts <- forecast(fitsts,12)
plot(prevsts)
```



Le package `forecast` permet de faire des **prévisions** à partir de la méthode STL

```
library(forecast)
y <- read.table("c://R//data//demandbrut.txt")
yy <- ts(data = y, start=c(1996,01),frequency=12)
fitstl <- stlm(yy)
# 6-ahead forecasts
prevstl <- forecast(fitstl,12)
plot(prevstl)
# or
yy <- ts(y[1:264,1],frequency=12)
prevstl = stlf(yy,12)
```




Figure: Comparaison des prévisions par X13-ARIMA-SEAT, STL, STS et TBATS

Prévisions	janv-18	févr-18	mars-18	avr-18
X13-ARIMA-SEATS	3 636.42	3 603.66	3 480.88	3 339.44
STL	3 628.69	3 587.48	3 470.21	3 345.75
STS	3 665.72	3 685.35	3 639.58	3 569.22
TBATS	3 624.80	3 578.57	3 483.59	3 385.26
<b>réalisée</b>	<b>3 636.60</b>	<b>3 565.90</b>	<b>3 441.20</b>	<b>3 324.90</b>
Erreurs de prévision				
X13-ARIMA-SEATS	0.18	-37.76	-39.68	-14.54
STL	7.91	-21.58	-29.01	-20.85
STS	-29.12	-119.45	-198.38	-244.32
TBATS	11.80	-12.67	-42.39	-60.36

Figure: Evolution des prévisions par X13-ARIMA-SEAT, STL, STS et TBATS




Figure: Comparaison des estimations révisées de la série CVS par Tramo-Seats

